

CS 224N Winter 2026 Assignment 2

Word2Vec and Dependency Parsing

1. Understanding word2vec (20 points)

Ý tưởng cốt lõi đằng sau mô hình word2vec là học các biểu diễn vector (embeddings) của từ dựa trên ngữ cảnh xuất hiện của chúng theo nguyên lý "một từ được định nghĩa bởi các từ đi cùng với nó". Dưới đây là lời giải chi tiết và đầy đủ về mặt toán học cho các câu hỏi từ (a) đến (g).

Question 1(a) — Equivalence to Cross-Entropy Loss

Phân phối thực tế $\mathbf{y}$ là một vector one-hot đại diện cho từ bên ngoài thực tế (outside word) o trong từ điển Vocab. Theo định nghĩa của hàm one-hot, ta có:

$$\mathbf{y}_w = \begin{cases} 1 & \text{nếu } w = o \\ 0 & \text{nếu } w \neq o \end{cases}$$

Khai triển biểu thức tổng độ mất mát Cross-Entropy trên toàn bộ từ điển:

$$- \sum_{w \in \text{Vocab}} \mathbf{y}_w \log(\hat{\mathbf{y}}_w) = - \left(\mathbf{y}_o \log(\hat{\mathbf{y}}_o) + \sum_{w \neq o} \mathbf{y}_w \log(\hat{\mathbf{y}}_w) \right)$$

Thay các giá trị thành phần của vector one-hot vào phương trình, ta được:

$$= - \left(1 \cdot \log(\hat{\mathbf{y}}_o) + \sum_{w \neq o} 0 \cdot \log(\hat{\mathbf{y}}_w) \right) = -\log(\hat{\mathbf{y}}_o)$$

Theo định nghĩa phân phối xác suất dự đoán được đưa ra bởi mô hình ở Phương trình (1), xác suất dự đoán cho từ ngữ cảnh thực tế chính là $\hat{\mathbf{y}}_o = P(O = o \mid C = c)$. Do đó, ta có:

$$-\log(\hat{\mathbf{y}}_o) = -\log P(O = o \mid C = c) = \mathbf{J}_{\text{naive-softmax}}(\mathbf{v}_c, o, \mathbf{U})$$

Điều này chứng minh rằng hàm mất mát naive-softmax hoàn toàn tương đương với hàm mất mát cross-entropy giữa $\mathbf{y}$ và $\hat{\mathbf{y}}$.

Question 1(b) — Gradient with respect to Center Word Vector

i. Phép tính đạo hàm riêng và dạng Vector hóa

Hàm mục tiêu naive-softmax được viết lại dưới dạng tường minh như sau:

$$\mathbf{J} = -\mathbf{u}_o^\top \mathbf{v}_c + \log \sum_{w \in \text{Vocab}} \exp(\mathbf{u}_w^\top \mathbf{v}_c)$$

Áp dụng quy tắc đạo hàm hàm hợp (Chain Rule) theo vector từ trung tâm $\mathbf{v}_c$:

$$\frac{\partial \mathbf{J}}{\partial \mathbf{v}_c} = -\mathbf{u}_o + \frac{1}{\sum_{w \in \text{Vocab}} \exp(\mathbf{u}_w^\top \mathbf{v}_c)} \cdot \sum_{w \in \text{Vocab}} \exp(\mathbf{u}_w^\top \mathbf{v}_c) \mathbf{u}_w$$

Đưa đại lượng phân số vào bên trong dấu tổng:

$$\frac{\partial \mathbf{J}}{\partial \mathbf{v}_c} = -\mathbf{u}_o + \sum_{w \in \text{Vocab}} \left(\frac{\exp(\mathbf{u}_w^\top \mathbf{v}_c)}{\sum_{x \in \text{Vocab}} \exp(\mathbf{u}_x^\top \mathbf{v}_c)} \right) \mathbf{u}_w$$

Nhận xét thấy cụm trong ngoặc vuông chính là xác suất dự đoán của mô hình $\hat{\mathbf{y}}_w$ đối với từ w :

$$\frac{\partial \mathbf{J}}{\partial \mathbf{v}_c} = -\mathbf{u}_o + \sum_{w \in \text{Vocab}} \hat{\mathbf{y}}_w \mathbf{u}_w$$

Để chuyển sang dạng vector hóa hoàn toàn (vectorized form) không còn ký hiệu tổng $\sum$, ta nhận thấy tổng $\sum_w \hat{\mathbf{y}}_w \mathbf{u}_w$ chính là phép nhân ma trận $\mathbf{U}$ với vector xác suất $\hat{\mathbf{y}}$. Đồng thời, vector từ thực tế $\mathbf{u}_o$ có thể biểu diễn qua phép nhân ma trận $\mathbf{U}$ với vector one-hot $\mathbf{y}$ ($\mathbf{u}_o = \mathbf{U}\mathbf{y}$). Do đó:

$$\frac{\partial \mathbf{J}}{\partial \mathbf{v}_c} = \mathbf{U}\hat{\mathbf{y}} - \mathbf{U}\mathbf{y} = \mathbf{U}(\hat{\mathbf{y}} - \mathbf{y})$$

ii. Điều kiện để Gradient triệt tiêu bằng 0

Gradient triệt tiêu (bằng 0) khi phương trình sau được thỏa mãn:

$$\mathbf{U}(\hat{\mathbf{y}} - \mathbf{y}) = 0$$

Điều này xảy ra khi phân phối xác suất mà mô hình dự đoán trùng khớp tuyệt đối với phân phối thực tế thực nghiệm:

$$\hat{\mathbf{y}} = \mathbf{y}$$

Nói cách khác, mô hình đạt trạng thái tối ưu lý tưởng khi gán xác suất tuyệt đối bằng 1 cho từ ngữ cảnh đúng ($\hat{\mathbf{y}}_o = 1$) và bằng 0 cho tất cả các từ khác.

iii. Ý nghĩa trực giác của các số hạng

Khi cập nhật vector từ theo phương pháp Gradient Descent: $\mathbf{v}_c^{(\text{new})} = \mathbf{v}_c - \eta \frac{\partial \mathbf{J}}{\partial \mathbf{v}_c} = \mathbf{v}_c + \eta \mathbf{u}_o - \eta \sum_{w \in \text{Vocab}} \hat{\mathbf{y}}_w \mathbf{u}_w$.

- **Số hạng thứ nhất ($+\eta \mathbf{u}_o$):** Đóng vai trò kéo vector từ trung tâm $\mathbf{v}_c$ dịch chuyển lại gần hơn về phía vector của từ ngữ cảnh thực tế $\mathbf{u}_o$, giúp tăng độ tương đồng (tích vô hướng) giữa từ trung tâm và ngữ cảnh đúng.
- **Số hạng thứ hai ($-\eta \sum \hat{\mathbf{y}}_w \mathbf{u}_w$):** Đóng vai trò đẩy vector từ trung tâm $\mathbf{v}_c$ ra xa khỏi tất cả các vector từ khác $\mathbf{u}_w$ trong từ điển. Cường độ đẩy tỉ lệ thuận với mức độ tự tin sai lầm (xác suất dự đoán $\hat{\mathbf{y}}_w$) mà mô hình gán sai cho chúng.

Question 1(c) — Analysis of L2 Normalization Effect

Giả sử có hai từ riêng biệt $x \neq y$ thỏa mãn quan hệ tỉ lệ hình học $\mathbf{u}_x = \alpha \mathbf{u}_y$ với hệ số dương $\alpha > 0$. Khi thực hiện chuẩn hóa L2, các vector được đưa về cùng độ dài đơn vị:

$$\frac{\mathbf{u}_x}{\|\mathbf{u}_x\|_2} = \frac{\alpha \mathbf{u}_y}{\|\alpha \mathbf{u}_y\|_2} = \frac{\alpha \mathbf{u}_y}{\alpha \|\mathbf{u}_y\|_2} = \frac{\mathbf{u}_y}{\|\mathbf{u}_y\|_2}$$

Như vậy sau khi chuẩn hóa, hai vector này hoàn toàn trùng khít nhau về mặt hình học.

- **Khi nào làm mất thông tin hữu ích:** Việc chuẩn hóa sẽ gây hại nếu độ dài của vector ban đầu chứa thông tin về cường độ hoặc tầm quan trọng ngữ nghĩa cho tác vụ phân loại cụm từ. Ví dụ, từ x là "excellent" (rất xuất sắc) có thể có độ dài vector lớn hơn từ y là "good" (tốt). Nếu áp dụng chuẩn hóa L2, hai từ này đóng góp một trọng số ngang nhau khi tính tổng embedding của cụm từ, làm mất đi sắc thái mạnh/yếu giúp ích cho bộ phân loại nhị phân nhận biết mức độ tích cực/tiêu cực.
- **Khi nào KHÔNG làm mất thông tin:** Việc chuẩn hóa sẽ có lợi nếu độ dài lớn của vector thô thuần túy là do nhiễu hệ thống (ví dụ: từ xuất hiện quá nhiều lần trong tập dữ liệu huấn luyện khiến biên độ vector bị kéo dài một cách nhân tạo). Lúc này, đưa vector về độ dài tiêu chuẩn giúp mô hình tập trung hoàn toàn vào hướng ngữ nghĩa, nâng cao độ chính xác của bài toán phân loại.

Question 1(d) — Partial Derivative with respect to Matrix $\mathbf{U}$

Theo quy ước hình dạng (shape convention) đối với ma trận tham số $\mathbf{U} = [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \dots \quad \mathbf{u}_{|\text{Vocab}|}]$, đạo hàm riêng của hàm mất mát theo ma trận $\mathbf{U}$ được biểu diễn dưới dạng một ma trận sắp xếp các đạo hàm riêng theo từng vector cột tương ứng:

$$\frac{\partial \mathbf{J}}{\partial \mathbf{U}} = \begin{bmatrix} \frac{\partial \mathbf{J}}{\partial \mathbf{u}_1} & \frac{\partial \mathbf{J}}{\partial \mathbf{u}_2} & \dots & \frac{\partial \mathbf{J}}{\partial \mathbf{u}_{|\text{Vocab}|}} \end{bmatrix}$$

Question 1(e) — Partial Derivative with respect to Outside Word Vectors

Hàm mất mát naive-softmax ban đầu được khai triển đối với một từ w bất kỳ: $\mathbf{J} = -\mathbf{u}_o^\top \mathbf{v}_c + \log \sum_{x \in \text{Vocab}} \exp(\mathbf{u}_x^\top \mathbf{v}_c)$. Ta tính đạo hàm bằng cách xét hai trường hợp cụ thể:

- **Trường hợp 1: Khi $w = o$ (Từ bên ngoài thực tế)**

Từ $\mathbf{u}_o$ xuất hiện ở cả số hạng tuyến tính đầu tiên và bên trong hàm tổng của số hạng thứ hai:

$$\frac{\partial \mathbf{J}}{\partial \mathbf{u}_o} = -\mathbf{v}_c + \left(\frac{\exp(\mathbf{u}_o^\top \mathbf{v}_c)}{\sum_{x \in \text{Vocab}} \exp(\mathbf{u}_x^\top \mathbf{v}_c)} \right) \mathbf{v}_c = -\mathbf{v}_c + \hat{\mathbf{y}}_o \mathbf{v}_c = (\hat{\mathbf{y}}_o - 1) \mathbf{v}_c$$

Vì với từ thực tế o , đại lượng one-hot $\mathbf{y}_o = 1$, ta viết lại được dưới dạng: $\frac{\partial \mathbf{J}}{\partial \mathbf{u}_o} = (\hat{\mathbf{y}}_o - \mathbf{y}_o) \mathbf{v}_c$.

- **Trường hợp 2: Khi $w \neq o$ (Tất cả các từ còn lại trong từ điển)**

Từ $\mathbf{u}_w$ chỉ xuất hiện bên trong hàm tổng của số hạng thứ hai, số hạng đầu tiên triệt tiêu bằng 0:

$$\frac{\partial \mathbf{J}}{\partial \mathbf{u}_w} = 0 + \left(\frac{\exp(\mathbf{u}_w^\top \mathbf{v}_c)}{\sum_{x \in \text{Vocab}} \exp(\mathbf{u}_x^\top \mathbf{v}_c)} \right) \mathbf{v}_c = \hat{\mathbf{y}}_w \mathbf{v}_c$$

Vì với $w \neq o$, giá trị one-hot $\mathbf{y}_w = 0$, ta có thể viết dưới dạng tương đương: $\frac{\partial \mathbf{J}}{\partial \mathbf{u}_w} = (\hat{\mathbf{y}}_w - \mathbf{y}_w) \mathbf{v}_c$.

Kết luận tổng quát: Đối với một từ bất kỳ w thuộc từ điển, đạo hàm riêng được hợp nhất thành một biểu thức duy nhất:

$$\frac{\partial \mathbf{J}}{\partial \mathbf{u}_w} = (\hat{\mathbf{y}}_w - \mathbf{y}_w) \mathbf{v}_c$$

Question 1(f) — Derivative of Leaky ReLU

Hàm kích hoạt Leaky ReLU được định nghĩa dưới dạng hàm phân nhánh như sau:

$$f(x) = \begin{cases} x & \text{nếu } x > 0 \\ \alpha x & \text{nếu } x \leq 0 \end{cases}$$

Lấy đạo hàm riêng của hàm số $f(x)$ theo biến vô hướng x , ta thu được:

$$f'(x) = \begin{cases} 1 & \text{nếu } x > 0 \\ \alpha & \text{nếu } x < 0 \end{cases}$$

Lưu ý toán học: Tại điểm gãy $x = 0$, hàm số không tồn tại đạo hàm giải tích chính thống nếu $\alpha \neq 1$. Tuy nhiên, trong thực tiễn tính toán của học sâu, giá trị tại điểm này thường được gán bằng α hoặc 1 dưới dạng dưới đạo hàm (subgradient).

Question 1(g) — Derivative of Sigmoid Function

Hàm Sigmoid được cho bởi công thức: $\sigma(x) = (1 + e^{-x})^{-1}$. Áp dụng quy tắc đạo hàm hàm hợp thương số:

$$\frac{d}{dx}\sigma(x) = -(1 + e^{-x})^{-2} \cdot (-e^{-x}) = \frac{e^{-x}}{(1 + e^{-x})^2}$$

Tách biểu thức phân số trên thành tích của hai phân số thành phần:

$$\frac{d}{dx}\sigma(x) = \left(\frac{1}{1 + e^{-x}} \right) \cdot \left(\frac{e^{-x}}{1 + e^{-x}} \right) = \sigma(x) \cdot \left(\frac{1 + e^{-x} - 1}{1 + e^{-x}} \right)$$

Biến đổi số hạng phân số thứ hai bằng cách thêm bớt 1 ở tử số:

$$= \sigma(x) \cdot \left(1 - \frac{1}{1 + e^{-x}} \right) = \sigma(x)(1 - \sigma(x))$$

Kết quả cuối cùng thu được biểu diễn gọn gàng qua chính hàm số $\sigma(x)$.

2. Neural Networks Optimization (8 points)

Question 2(a) — Adam Optimizer

i. Giải thích trực giác về thành phần Quán tính (Momentum — $\mathbf{m}$)

Thành phần momentum ($\mathbf{m}$) hoạt động như một trung bình trượt có trọng số của các gradient trong quá khứ, giúp tích lũy vận tốc theo hướng nhất quán và triệt tiêu các dao động trái dấu ở các hướng không ổn định. Điều này làm giảm đáng kể phương sai của các bước cập nhật, giúp quỹ đạo tối ưu hóa bớt đi đường vòng (zig-zag) và tiến nhanh hơn về phía cực tiểu cục bộ. Nhờ có phương sai thấp, quá trình huấn luyện diễn ra ổn định hơn, cho phép sử dụng tốc độ học (learning rate) lớn hơn mà không sợ mô hình bị phân kỳ.

ii. Cơ chế của Tốc độ học thích ứng (Adaptive Learning Rates — v)

Các tham số có gradient với kích thước nhỏ (hoặc ít khi được cập nhật) sẽ nhận được các bước cập nhật lớn hơn, bởi vì giá trị $\sqrt{v}$ ở mẫu số của chúng rất nhỏ. Ngược lại, các tham số có gradient lớn hoặc biến động liên tục sẽ bị kìm hãm lại bởi mẫu số lớn để tránh nhảy quá xa khỏi vùng tối ưu. Cơ chế này giúp ích cho việc huấn luyện bằng cách đảm bảo tất cả các tham số (ngay cả các đặc trưng hiếm gặp — sparse features) đều được học với một tốc độ hiệu quả và đồng đều, ngăn chặn hiện tượng một số trọng số bị bỏ lại phía sau.

Question 2(b) — Dropout

i. Tính giá trị của hằng số γ theo p_{drop}

Theo định nghĩa từ đề bài, ta có biểu thức thành phần thứ i của vector $\mathbf{h}_{\text{drop}}$ là:

$$[\mathbf{h}_{\text{drop}}]_i = \gamma \cdot d_i \cdot h_i$$

Trong đó, d_i là một biến ngẫu nhiên Bernoulli nhận giá trị bằng 0 với xác suất p_{drop} , và bằng 1 với xác suất $(1 - p_{\text{drop}})$. Do đó, kỳ vọng của d_i là:

$$\mathbb{E}[d_i] = 0 \cdot p_{\text{drop}} + 1 \cdot (1 - p_{\text{drop}}) = 1 - p_{\text{drop}}$$

Lấy kỳ vọng hai vế của biểu thức $[\mathbf{h}_{\text{drop}}]_i$ (chú ý rằng γ và h_i là các đại lượng cố định trong một minibatch cụ thể):

$$\mathbb{E}_{p_{\text{drop}}}[\mathbf{h}_{\text{drop}}]_i = \mathbb{E}_{p_{\text{drop}}}[\gamma \cdot d_i \cdot h_i] = \gamma \cdot h_i \cdot \mathbb{E}[d_i] = \gamma \cdot h_i \cdot (1 - p_{\text{drop}})$$

Để thỏa mãn điều kiện đề bài yêu cầu $\mathbb{E}_{p_{\text{drop}}}[\mathbf{h}_{\text{drop}}]_i = h_i$, ta thiết lập phương trình cân bằng:

$$\gamma \cdot h_i \cdot (1 - p_{\text{drop}}) = h_i \implies \gamma \cdot (1 - p_{\text{drop}}) = 1 \implies \gamma = \frac{1}{1 - p_{\text{drop}}}$$

Kết luận: Giá trị của hằng số γ phải bằng $\frac{1}{1 - p_{\text{drop}}}$.

ii. Áp dụng Dropout trong huấn luyện và đánh giá

Trong quá trình huấn luyện (training), Dropout ngẫu nhiên tắt đi các node mạng để phá vỡ sự phụ thuộc đồng thích ứng (co-adaptation) giữa các neuron, ép mạng neural phải học các đặc trưng mạnh mẽ và độc lập hơn nhằm chống quá khớp (overfitting). Trong khi đó, ở bước đánh giá (evaluation), ta cần mô hình đưa ra dự đoán mang tính nhất quán, chính xác và khai thác toàn bộ tri thức của mạng một cách ổn định nhất. Việc giữ lại toàn bộ các node (không bật Dropout) ở giai đoạn này đóng vai trò tương tự như việc kết hợp trung bình một tập hợp (ensemble) gồm rất nhiều mạng con đã được tối ưu hóa.

Question 3(b) — Tổng số bước dịch chuyển theo n

Một câu chứa n từ sẽ được phân tích cú pháp hoàn chỉnh trong đúng $2n$ bước.

Giải thích: Ban đầu, tất cả n từ đều nằm trong bộ đệm (Buffer). Để xử lý, mỗi từ bắt buộc phải được đưa vào ngăn xếp (Stack) thông qua đúng 1 hành động SHIFT, tổng cộng là n bước

SHIFT. Sau đó, để xây dựng cây cú pháp phụ thuộc, mỗi từ trong số n từ này (ngoại trừ nút ROOT) phải bị xóa khỏi Stack thông qua đúng 1 hành động tạo vòng cung (LEFT-ARC hoặc RIGHT-ARC), tổng cộng là n bước dựng cung. Do đó, hệ thống luôn thực hiện chính xác $n + n = 2n$ bước để hoàn thành việc phân tích một câu.

Question 3(e) — Đạo hàm mạng Neural Dependency Parser

i. Đạo hàm của lớp ẩn $\mathbf{h} = \text{ReLU}(\mathbf{xW} + \mathbf{b}_1)$ theo vector đầu vào $\mathbf{x}$

Đặt trạng thái kích hoạt trước lớp ẩn là $\mathbf{z} = \mathbf{xW} + \mathbf{b}_1$, khi đó $\mathbf{h} = \text{ReLU}(\mathbf{z})$. Khai triển theo từng phần tử cho chỉ số lớp ẩn i và chỉ số đầu vào j :

$$z_i = \sum_k x_k W_{ki} + b_{1,i}$$

Lấy đạo hàm riêng của z_i theo thành phần đầu vào x_j :

$$\frac{\partial z_i}{\partial x_j} = W_{ji}$$

Áp dụng quy tắc đạo hàm hàm hợp (Chain Rule) để tính đạo hàm riêng $\frac{\partial h_i}{\partial x_j}$:

$$\frac{\partial h_i}{\partial x_j} = \frac{\partial h_i}{\partial z_i} \cdot \frac{\partial z_i}{\partial x_j}$$

Vì hàm kích hoạt là $\text{ReLU}(z) = \max(z, 0)$, đạo hàm của nó là hàm chỉ dấu $\mathbf{1}(z > 0)$. Do đó, ta thu được kết quả chi tiết cho cặp chỉ số bất kỳ:

$$\frac{\partial h_i}{\partial x_j} = \mathbf{1}(z_i > 0) \cdot W_{ji} = \begin{cases} W_{ji} & \text{nếu } (\mathbf{xW} + \mathbf{b}_1)_i > 0 \\ 0 & \text{ngược lại} \end{cases}$$

ii. Đạo hàm của hàm mất mát $J(\theta)$ theo logits $\mathbf{l}_i$

Hàm mất mát Cross-Entropy đối với bài toán phân loại 3 hành động dịch chuyển ($|\text{logits}| = 3$) được định nghĩa là:

$$J(\theta) = - \sum_{j=1}^3 \mathbf{y}_j \log \hat{\mathbf{y}}_j$$

Trong đó, phân phối dự đoán $\hat{\mathbf{y}}$ được tính từ logits $\mathbf{l}$ thông qua hàm Softmax: $\hat{\mathbf{y}}_j = \frac{e^{l_j}}{\sum_{k=1}^3 e^{l_k}}$.

Áp dụng quy tắc đạo hàm hàm hợp tổng quát, ta có:

$$\frac{\partial J}{\partial l_i} = \sum_{j=1}^3 \frac{\partial J}{\partial \hat{\mathbf{y}}_j} \cdot \frac{\partial \hat{\mathbf{y}}_j}{\partial l_i}$$

Mặt khác, ta biết đạo hàm riêng của hàm mất mát theo dự đoán là $\frac{\partial J}{\partial \hat{\mathbf{y}}_j} = -\frac{\mathbf{y}_j}{\hat{\mathbf{y}}_j}$, và đạo hàm riêng của hàm Softmax được chia làm hai trường hợp:

$$\frac{\partial \hat{\mathbf{y}}_j}{\partial l_i} = \begin{cases} \hat{\mathbf{y}}_i(1 - \hat{\mathbf{y}}_i) & \text{khi } j = i \\ -\hat{\mathbf{y}}_j \hat{\mathbf{y}}_i & \text{khi } j \neq i \end{cases}$$

Thay các thành phần này vào chuỗi Chain Rule, ta thu được:

$$\begin{aligned}\frac{\partial J}{\partial l_i} &= -\frac{\mathbf{y}_i}{\hat{\mathbf{y}}_i} \cdot [\hat{\mathbf{y}}_i(1 - \hat{\mathbf{y}}_i)] + \sum_{j \neq i} \left(-\frac{\mathbf{y}_j}{\hat{\mathbf{y}}_j} \right) \cdot (-\hat{\mathbf{y}}_j \hat{\mathbf{y}}_i) \\ \frac{\partial J}{\partial l_i} &= -\mathbf{y}_i(1 - \hat{\mathbf{y}}_i) + \sum_{j \neq i} \mathbf{y}_j \hat{\mathbf{y}}_i = -\mathbf{y}_i + \mathbf{y}_i \hat{\mathbf{y}}_i + \sum_{j \neq i} \mathbf{y}_j \hat{\mathbf{y}}_i\end{aligned}$$

Nhóm nhân tử chung $\hat{\mathbf{y}}_i$ ra ngoài, ta có cấu trúc tổng xác suất thực tế $\sum_{j=1}^3 \mathbf{y}_j = 1$ (vì $\mathbf{y}$ là vector một phần tử kích hoạt duy nhất — vector one-hot):

$$\frac{\partial J}{\partial l_i} = -\mathbf{y}_i + \hat{\mathbf{y}}_i \left(\sum_{j=1}^3 \mathbf{y}_j \right) = \hat{\mathbf{y}}_i - \mathbf{y}_i$$

Viết gọn dưới dạng vector hóa cho toàn bộ thành phần lớp logits $\mathbf{l}$ chính là:

$$\frac{\partial J(\theta)}{\partial \mathbf{l}} = \hat{\mathbf{y}} - \mathbf{y}$$